

Advanced Machine Learning

Rezolvări explicate - examen 21 iunie 2024

Cum să folosești documentul

Fiecare exercițiu este transcris în formă matematică, apoi rezolvat cu explicații pas cu pas. Am păstrat notația standard: $VCdim$ pentru dimensiunea VC, $\tau_H(m)$ pentru growth function, iar 1_A pentru funcția indicator.

Cuprins

- Exercițiul 1 - Exemple pentru $VCdim(H_1 \cup H_2)$
- Exercițiul 2 - Bile centrate în origine: $VCdim$ și shattering coefficient
- Exercițiul 3 - ERM pentru intervale $[a, a+1]$, cazul realizabil și agnostic
- Exercițiul 4 - Clasa duală și bound-ul $VCdim(Z) < 2^{VCdim(H)+1}$

Exercițiul 1

Cerință

Dați exemple de două clase de ipoteze H_1 și H_2 astfel încât:

$$a) VCdim(H_1 \cup H_2) = \max\{VCdim(H_1), VCdim(H_2)\}$$

$$b) VCdim(H_1 \cup H_2) > \max\{VCdim(H_1), VCdim(H_2)\}$$

Justificați răspunsurile.

Ideea teoretică

Reuniunea a două clase nu trebuie să aibă neapărat aceeași dimensiune VC ca cea mai mare dintre cele două clase. Uneori nu crește deloc, alteori crește deoarece ipotezele din cele două clase se completează reciproc.

a) Exemplu unde dimensiunea VC nu crește

Luăm spațiul de instanțe $X = \mathbb{R}$. Definim:

$$H_1 = \{ h_a(x) = 1_{[a, \infty)}(x) : a \in \mathbb{R} \}$$

$$H_2 = \{ h_0 \}, \text{ unde } h_0(x) = 0 \text{ pentru orice } x \in \mathbb{R}.$$

Clasa H_1 este clasa threshold-urilor la dreapta. Ea produce etichete de forma 000...111 pe puncte ordonate crescător.

Un singur punct poate fi shatter-uit: alegem pragul înaintea lui pentru eticheta 1 și după el pentru eticheta 0. Două puncte $x_1 < x_2$ nu pot fi shatter-uite, pentru că etichetarea 10 este imposibilă: dacă x_1 este 1, atunci automat x_2 este 1.

$$VCdim(H_1) = 1.$$

Clasa H_2 conține doar funcția constantă 0, deci nu poate shatter-ui nici măcar un punct:

$$VCdim(H_2) = 0.$$

Reuniunea $H_1 \cup H_2$ nu adaugă nimic esențial, deoarece H_1 putea deja să producă etichetarea cu toate punctele 0, alegând un prag mai mare decât toate punctele.

$$VCdim(H_1 \cup H_2) = 1 = \max\{1, 0\} = \max\{VCdim(H_1), VCdim(H_2)\}.$$

b) Exemplu unde dimensiunea VC crește

Luăm din nou $X = \mathbb{R}$, dar acum:

$$H_1 = \{ 1_{[a, \infty)} : a \in \mathbb{R} \} \quad \text{threshold-uri la dreapta}$$

$$H_2 = \{ 1_{(-\infty, a]} : a \in \mathbb{R} \} \quad \text{threshold-uri la stânga}$$

Fiecare clasă separat are $VCdim$ egală cu 1, deoarece fiecare poate shatter-ui un punct, dar nu poate shatter-ui două puncte.

Arătăm că reuniunea poate shatter-ui două puncte $x_1 < x_2$. Trebuie să obținem toate etichetările: 00, 01, 10, 11.

00: folosim H_1 cu $a > x_2$.

01: folosim H_1 cu $x_1 < a \leq x_2$.

10: folosim H_2 cu $x_1 \leq a < x_2$.

11: folosim H_1 cu $a \leq x_1$.

Deci două puncte sunt shatter-uite de $H_1 \cup H_2$. Trei puncte nu pot fi shatter-uite: pentru $x_1 < x_2 < x_3$, etichetarea 101 este imposibilă. Un threshold la dreapta produce doar 000, 001, 011, 111; un

threshold la stânga produce doar 111, 110, 100, 000.

$$\text{VCdim}(H_1 \cup H_2) = 2 > 1 = \max\{\text{VCdim}(H_1), \text{VCdim}(H_2)\}.$$

Exercițiul 2

Cerință

Fie, pentru $n \geq 1$, clasa de ipoteze:

$$H_n = \{ h_a : \mathbb{R}^n \rightarrow \{0,1\} \mid h_a(x) = 1_{[0,a]}(\|x\|_2), a > 0 \},$$

$$\text{unde } \|x\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}.$$

a) Calculați $\text{VCdim}(H_n)$ pentru $n \geq 1$. b) Calculați shattering coefficient-ul $\tau_{H_n}(m)$, pentru $m \geq 0$.

Interpretare

Avem $h_a(x) = 1$ dacă și numai dacă $\|x\|_2 \leq a$. Deci fiecare ipoteză este o bilă centrată în origine, cu rază a . Singurul parametru liber este raza; centrul nu se mișcă.

a) Dimensiunea VC

Clasa se comportă ca un threshold pe distanța față de origine. Pentru un punct $x \neq 0$, notăm $r = \|x\|_2$.

Pentru eticheta 1: alegem $a \geq r$.

Pentru eticheta 0: alegem $0 < a < r$.

Deci un punct poate fi shatter-uit, prin urmare $\text{VCdim}(H_n) \geq 1$.

Acum luăm două puncte x_1, x_2 , cu razele $r_1 = \|x_1\|_2$ și $r_2 = \|x_2\|_2$. Presupunem $r_1 < r_2$. Dacă punctul mai îndepărtat x_2 este pozitiv, adică $r_2 \leq a$, atunci $r_1 \leq r_2 \leq a$, deci și x_1 este pozitiv.

Prin urmare este imposibilă etichetarea în care punctul mai apropiat este 0 și punctul mai îndepărtat este 1. Niciun set de două puncte nu poate fi shatter-uit.

$\text{VCdim}(H_n) = 1$ pentru orice $n \geq 1$.

b) Growth function / shattering coefficient

Pentru a maximiza numărul de etichetări pe m puncte, alegem puncte cu distanțe distincte față de origine:

$$r_1 < r_2 < \dots < r_m.$$

O ipoteză h_a pune eticheta 1 tuturor punctelor cu $r_i \leq a$ și 0 celor cu $r_i > a$. Etichetările posibile sunt prefixe de 1 urmate de 0:

```
000...0
100...0
110...0
...
111...1
```

Sunt exact $m+1$ posibilități. Nu pot exista mai multe, deoarece dacă un punct mai îndepărtat este 1, atunci toate punctele mai apropiate sunt automat 1.

$\tau_{H_n}(m) = m + 1$ pentru orice $m \geq 0$.

Exercițiul 3

Cerință

Considerăm clasa de concepte C dată de intervalele închise $[a, a+1]$, unde $a \in \mathbb{R}$. Dați un algoritm ERM eficient pentru învățarea clasei C și calculați complexitatea în:

- a) cazul realizabil
- b) cazul agnostic

Ce înseamnă ERM aici

ERM înseamnă Empirical Risk Minimization: alegem intervalul $[a, a+1]$ care face cele mai puține greșeli pe setul de antrenare. Pentru un sample $S = \{(x_i, y_i)\}_{i=1}^n$, eroarea empirică este:

$$L_S(h_a) = (1/n) \cdot |\{i : h_a(x_i) \neq y_i\}|.$$

a) Cazul realizabil

În cazul realizabil există un interval $[a^*, a^*+1]$ care clasifică perfect toate exemplele. Notăm:

$$\begin{aligned} P &= \{x_i : y_i = 1\} && \text{mulțimea exemplelor pozitive} \\ N &= \{x_i : y_i = 0\} && \text{mulțimea exemplelor negative} \end{aligned}$$

Un punct pozitiv p trebuie să aparțină intervalului $[a, a+1]$. Condiția $p \in [a, a+1]$ este echivalentă cu:

$$p - 1 \leq a \leq p.$$

Pentru toate punctele pozitive, a trebuie să aparțină intersecției acestor intervale. Dacă P nu este vidă, obținem:

$$\begin{aligned} I &= [p_{\max} - 1, p_{\min}], \\ \text{unde } p_{\max} &= \max P \text{ și } p_{\min} = \min P. \end{aligned}$$

Un punct negativ z nu trebuie să fie în interval. Dar $z \notin [a, a+1]$ exact atunci când $a \geq [z-1, z]$. Deci fiecare negativ z produce un interval interzis pentru a :

$$[z - 1, z].$$

Algoritmul caută un punct a în I care nu se află în niciun interval interzis. În cazul realizabil, un astfel de a există. Dacă nu există pozitive, alegem un interval departe de toate punctele, de exemplu $a = \max_i x_i + 1$.

Implementare: calculăm $p_{\min}$ și $p_{\max}$ în $O(n)$, construim intervalele interzise în $O(n)$, le sortăm și verificăm dacă acoperă complet intervalul I .

Complexitate în cazul realizabil: $O(n \log n)$. Ipoteza returnată are eroare empirică 0, deci este ERM.

b) Cazul agnostic

În cazul agnostic nu presupunem că există un interval perfect. Trebuie să găsim intervalul de lungime 1 cu număr minim de greșeli.

Fie P numărul total de exemple pozitive. Pentru un interval $[a, a+1]$, notăm $P_{\text{in}}(a)$ numărul de pozitive în interval și $N_{\text{in}}(a)$ numărul de negative în interval. Numărul de greșeli este:

$$\text{err}(a) = P - P_{\text{in}}(a) + N_{\text{in}}(a).$$

Punem greutatea pe puncte: +1 pentru pozitive și -1 pentru negative. Pentru un interval, definim scorul:

$$\begin{aligned} \text{score}(a) &= \text{suma greutăților punctelor } x_i \in [a, a+1] \\ &= P_{\text{in}}(a) - N_{\text{in}}(a). \end{aligned}$$

Atunci $\text{err}(a) = P - \text{score}(a)$. Cum P este constant, minimizarea erorii este echivalentă cu maximizarea scorului.

Deci problema devine: găsește intervalul de lungime 1 cu sumă maximă a greutăților.

Este suficient să verificăm valori candidate ale lui a din mulțimea:

$$A = \{x_i : i=1, \dots, n\} \cup \{x_i - 1 : i=1, \dots, n\} \cup \{\max_i x_i + 1\}.$$

Sortăm punctele după coordonată și folosim sume prefixate ale greutăților. Pentru fiecare candidat a , găsim prin binary search punctele din $[a, a+1]$ și calculăm scorul rapid.

Complexitate în cazul agnostic: $O(n \log n)$. Algoritmul returnează intervalul de lungime 1 cu scor maxim, deci cu eroare empirică minimă.

Exercițiul 4

Cerință

Fie X un spațiu de instanțe și fie $H = \{0,1\}^X$ o clasă de ipoteze cu $\text{VCdim}(H)$ finită. Pentru fiecare $x \in X$, definim:

$$z_x : H \rightarrow \{0,1\}, \quad z_x(h) = h(x).$$

Fie:

$$Z = \{ z_x : H \rightarrow \{0,1\} \mid x \in X \}.$$

Demonstrați că:

$$\text{VCdim}(Z) \leq 2^{\text{VCdim}(H)+1}.$$

Interpretare

Clasa Z este clasa duală a lui H . În H , ipotezele primesc puncte x și returnează etichete. În Z , pentru fiecare punct x construim o funcție z_x care primește o ipoteză h și returnează $h(x)$. Deci rolurile punctelor și ipotezelor se inversează.

Demonstrație

Notăm $d = \text{VCdim}(H)$. Presupunem că Z shatter-uieste t ipoteze din H :

$$h_1, h_2, \dots, h_t \in H.$$

Asta înseamnă că pentru orice subset $A \subseteq \{1, \dots, t\}$, există un punct $x_A \in X$ astfel încât:

$$h_i(x_A) = 1 \iff i \in A.$$

Cu alte cuvinte, folosind puncte x din X , putem produce orice vector binar de lungime t pe ipotezele $h_1, \dots, h_t$.

Definim:

$$k = \lfloor \log_2 t \rfloor.$$

Atunci $2^k \leq t$. Alegem 2^k ipoteze dintre cele t și le asociem tuturor vectorilor binari de lungime k . Există exact 2^k astfel de vectori.

Pentru fiecare poziție $j = 1, \dots, k$, definim un subset A_j al indicilor ipotezelor: ipoteza h_i aparține lui A_j dacă al j -lea bit al vectorului asociat lui h_i este 1. Deoarece Z shatter-uieste ipotezele, pentru fiecare A_j există un punct $x_j \in X$ astfel încât:

$$h_i(x_j) = 1 \iff i \in A_j.$$

Am construit astfel k puncte $x_1, \dots, x_k$. Acum arătăm că H shatter-uieste aceste k puncte. Luăm orice vector binar $(b_1, \dots, b_k)$. Prin construcție, există una dintre ipotezele h_i a căreia i -am asociat exact acest vector. Pentru fiecare j avem:

$$h_i(x_j) = b_j.$$

Deci H poate realiza orice etichetare pe cele k puncte $x_1, \dots, x_k$. Prin urmare H le shatter-uieste, deci:

$$k \leq \text{VCdim}(H) = d.$$

Am obținut:

$$\lfloor \log_2 t \rfloor \leq d.$$

Aceasta implică $t < 2^{d+1}$. Dacă t ar fi cel puțin 2^{d+1} , atunci $\lfloor \log_2 t \rfloor$ ar fi cel puțin $d+1$, contradicție.

$$\text{VCdim}(Z) < 2^{(\text{VCdim}(H)+1)}.$$

Intuiție finală

Dacă duala Z ar putea shatter-ui foarte multe ipoteze din H , atunci am putea transforma aceste ipoteze într-un set mare de etichetări pe puncte din X . Asta ar forța H să shatter-uiască multe puncte, contradicând faptul că $\text{VCdim}(H) = d$.