Concepte și aplicații în Vederea Artificială

Bogdan Alexe

Radu Ionescu

bogdan.alexe@fmi.unibuc.ro

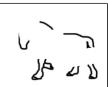
radu.ionescu@fmi.unibuc.ro

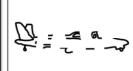
Curs opțional anii III/IV, semestrul I, 2024-2025

Cursul trecut

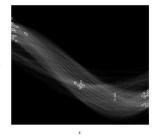
• Aplicații ale filtrelor: extragerea informației (muchii)







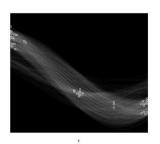
- Aplicație: detectarea liniilor cu
 - transformata Hough

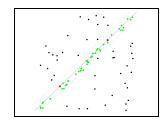


Cursul de azi

- Aplicație: detectarea liniilor cu
 - transformata Hough

- RANSAC



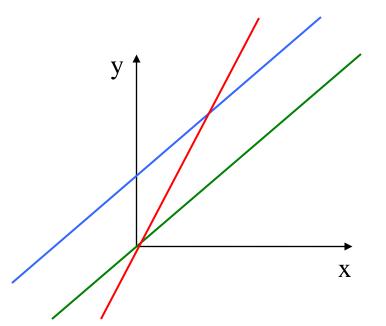


• Compararea contururilor



Aplicație: detectarea liniilor cu transformata Hough

Parametrizarea dreptelor. Exemple



$$d_1$$
: y = x, adică m=1, b = 0

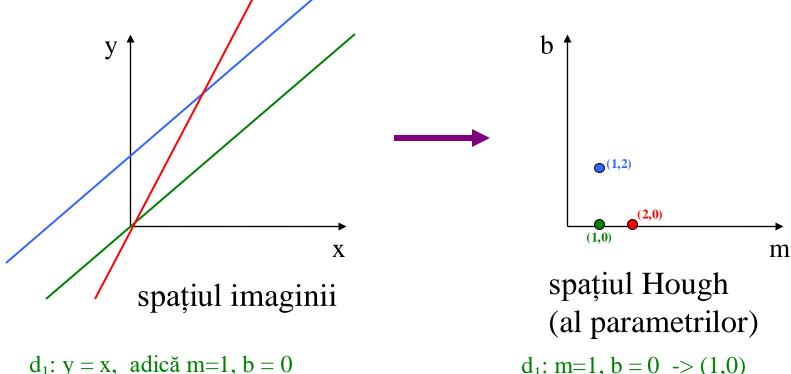
$$d_2$$
: y = x + 2, adică m=1, b = 2

$$d_3$$
: y = 2x, adică m=2, b = 0

Ecuația unei drepte în planul imaginii: y = m * x + b,

m – panta dreptei (definește înclinarea față de axa Ox), b – deplasarea (definește deplasarea față de originea O(0,0)) (m,b) sunt parametri dreptei

Spatiul Hough al parametrilor



$$d_2$$
: y = x + 2, adică m=1, b = 2

$$d_3$$
: y = 2x, adică m=2, b = 0

$$d_1$$
: m=1, b = 0 -> (1,0)

$$d_2$$
: m=1, b = 2 -> (1,2)

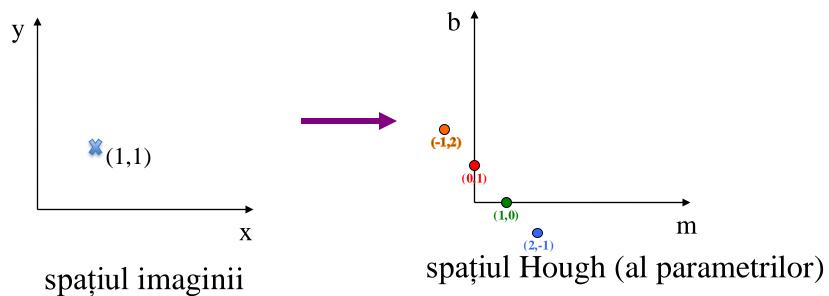
$$d_3$$
: m=2, b = 0 -> (2,0)

O dreaptă într-o imagine corespunde unui punct în spațiul Hough.

Corespondența dintre cele două spații

O dreaptă într-o imagine corespunde unui punct în spațiul Hough.

Un punct (x_0,y_0) în spațiul imaginii corespunde unei drepte în spațiul Hough.



Prin punctul (1,1) tree o infinitate de drepte de forma y = mx+b:

$$y = x$$
 (m=1, b=0); $y = 2x-1$ (m=2,b=-1), $y = 1$ (m=0, b = -1), $y = -x + 2$ (m=-1, b = 2),

Toate cele 4 puncte (1,0), (2,-1), (0,-1), (-1,2) stau pe dreapta b = -m+1

Corespondența dintre cele două spații

O dreaptă într-o imagine corespunde unui punct în spațiul Hough. Un punct (x_0,y_0) în spațiul imaginii corespunde unei drepte în spațiul Hough.

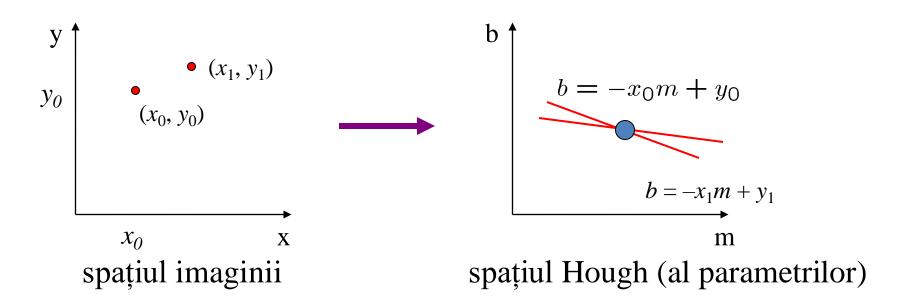
Ecuația unei drepte în planul imaginii: y = m * x + b,

Dreptele care trec prin punctul (x_0,y_0) pot avea orice pantă m și orice deplasare b cu condiția ca $y_0 = m * x_0 + b$.

$$y_0 = m * x_0 + b \Leftrightarrow b = -x_0 * m + y_0$$
 (dreapta cu panta $-x_0$ și deplasare y_0)

$$(x_0,y_0) = (1,1) \Longrightarrow b = -m+1$$

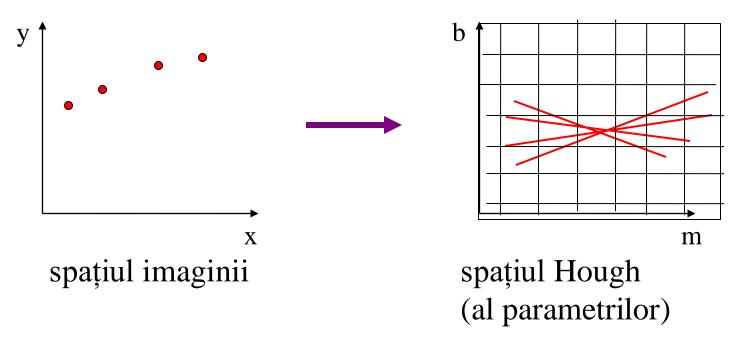
Găsirea liniilor într-o imagine folosind spațiul Hough



Care sunt parametri liniei care conține punctele (x_0, y_0) și (x_1, y_1) ?

Punctului (x_0,y_0) îi corespunde dreapta de ecuație $b=-x_0m+y_0$ Punctului (x_1,y_1) îi corespunde dreapta de ecuație $b=-x_1m+y_1$ Dreptei d care conține punctele (x_0,y_0) , (x_1,y_1) îi corespunde în spațiul Hough un punct. Acest punct se obține ca fiind intersecția dreptelor de ecuație $b=-x_0m+y_0$ și $b=-x_1m+y_1$. Apar probleme când $x_0=x_1$.

Găsirea liniilor într-o imagine: algoritmul Hough

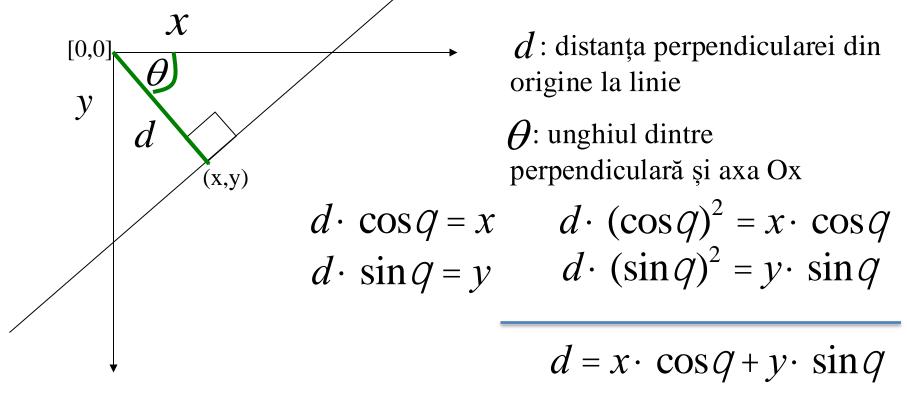


Cum putem folosi observația anterioară pentru a găsi parametri (m,b) ce definesc linia cea mai probabilă în spațiul imaginii?

- fiecare punct detectat ca fiind edgel în spațiul imaginii va vota pentru o mulțime de parametri în spațiul Hough
- acumulăm voturi în intervale discrete; parametri cu cel mai mare număr de voturi determină linia din spațul imaginii

Reprezentarea în coordonate polare pentru detectarea liniilor

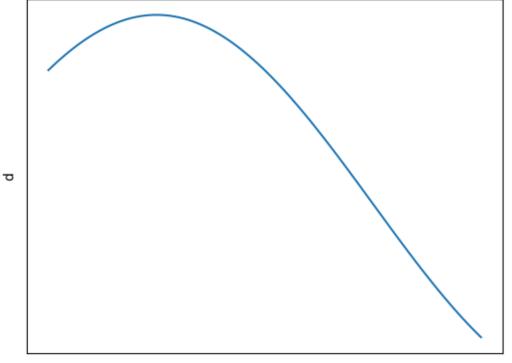
Probleme cu spațiul Hough al parametrilor (m,b): m poate lua o valoare infinită, probleme pentru linii verticale. Din acest motiv vom folosi o altă parametrizare (coordonate polare):



Punct în spațiul imaginii -> curbă sinusoidală în spațiul Hough

```
plot_curs5.py
     import numpy as np
     import matplotlib.pyplot as plt
     x, y = 1, 1
     theta = np.linspace(0,np.pi,100)
     d = x * np.cos(theta) + y*np.sin(theta)
     plt.figure
     plt.plot(theta,d)
     plt.xlabel('theta')
     plt.ylabel('d')
     plt.title('Graficul functie d = cos(theta) + sin(theta)')
10
     plt.show()
11
     print(d)
12
```

Graficul functie d = cos(theta) + sin(theta)



theta

```
plot_curs5.py
     import numpy as np
     import matplotlib.pyplot as plt
     x, y = 1, 1
     theta = np.linspace(0,np.pi,100)
     d = x * np.cos(theta) + y*np.sin(theta)
     plt.figure
     plt.plot(theta,d)
     plt.xlabel('theta')
     plt.ylabel('d')
     plt.title('Graficul functie d = cos(theta) + sin(theta)')
     #plt.show()
11
12
     print(d)
13
14
     x,y = 10,5
15
     d1 = x * np.cos(theta) + y*np.sin(theta)
     plt.figure
     plt.plot(theta,d1)
17
18
     plt.show()
```

Prin orice două puncte trece o dreaptă unică.

⇒ orice două curbe sinusoide în spațiul Hough se intersectează

```
plot_curs5.py
     import numpy as np
     import matplotlib.pyplot as plt
     x_{1}y = 1,1
     theta = np.linspace(0,np.pi,100)
     d = x * np.cos(theta) + y*np.sin(theta)
     plt.figure
     plt.plot(theta,d)
     plt.xlabel('theta')
     plt.ylabel('d')
     plt.title('Graficul functie d = cos(theta) + sin(theta)')
     #plt.show()
11
     print(d)
12
13
14
     x,y = 10,5
                                              Graficul functie d = cos(theta) + sin(theta)
15
     d1 = x * np.cos(theta)
     plt.figure
     plt.plot(theta,d1)
17
18
     plt.show()
                                    р
```

theta

Algoritmul transformatei Hough

folosește coordonate polare

$$x\cos q + y\sin q = d$$

Algoritmul transformatei Hough

- 1. inițializează H[d, θ]=0
- 2. pentru fiecare punct edgel din imagine I[x,y]

pentru
$$\theta = 0$$
 to 360 // $[0, 2*pi]$ e împărțit în intervale $d = x \cos Q + y \sin Q$
H[d, θ] += 1

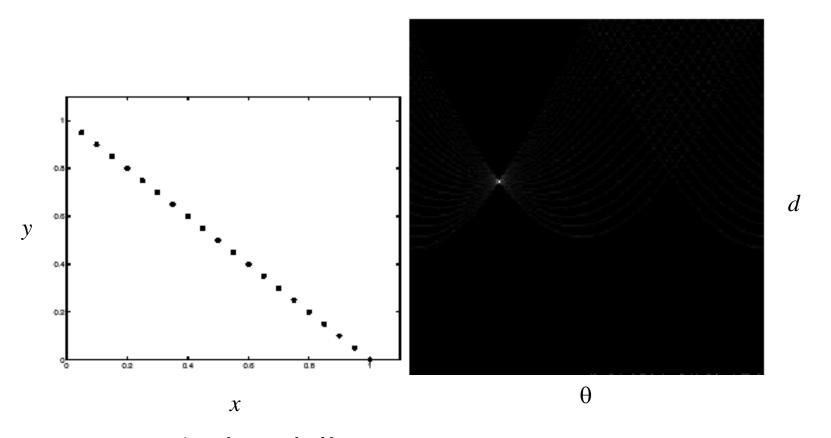
- 3. găsește valorile (d^* , θ^*) pentru care H[d^* , θ^*] este maxim
- linia detectată în imagine este dată de: $d^* = x \cos \theta^* + y \sin \theta^*$

DEMO:

H: accumulează voturi H

https://www.aber.ac.uk/~dcswww/Dept/Teaching/CourseNotes/current/CS34110/hough.html

Exemplu: transformata Hough pentru linii



spațiul imaginii coordonatele punctelor edgels

Voturi

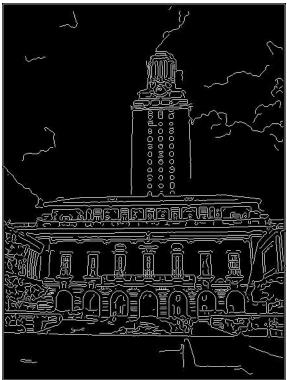
culoare deschisă = # mare de voturi negru = zero voturi

Exemplu: transformata Hough pentru linii

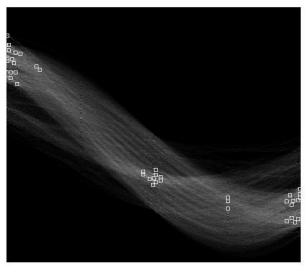
Pătrat:





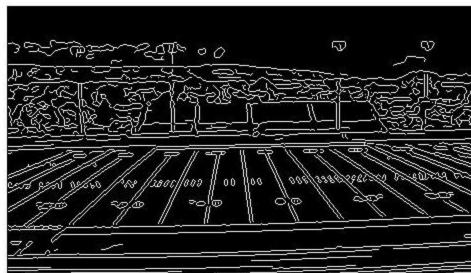


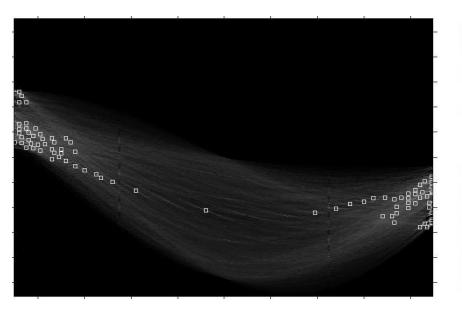




Slide adaptat după S. Lazebnik



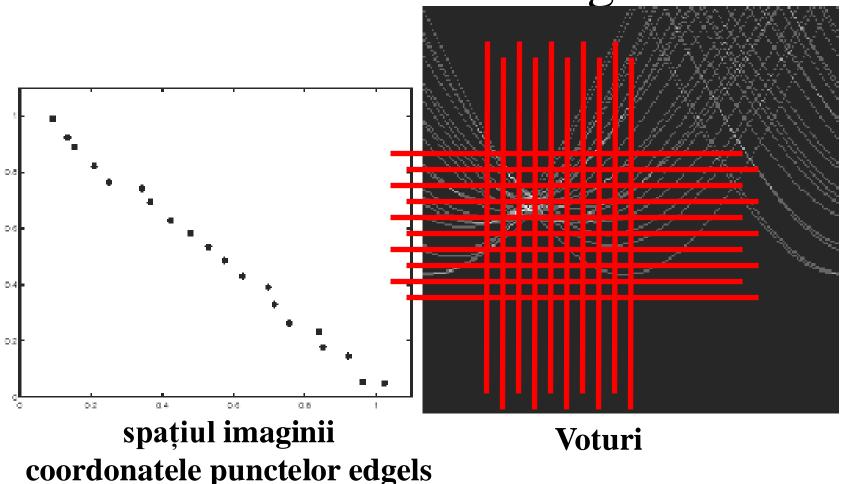






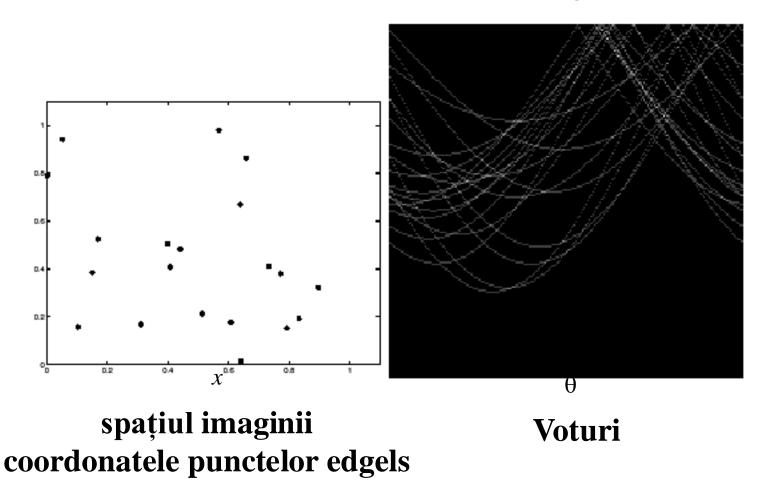
Sunt afișate cele mai lungi segmente

Impactul zgomotului asupra transformatei Hough



culoare deschisă = # mare de voturi negru = zero voturi

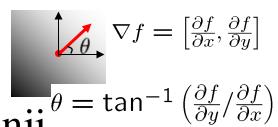
Impactul zgomotului asupra transformatei Hough



Totul pare a fi zgomot sau puncte edgels aleatoare. Se observă niște peak-uri în spațiul parametrilor.

Slide adaptat după S. Lazebnik

Extensii



$$\theta = \tan^{-1}\left(\frac{\partial f}{\partial y}/\frac{\partial f}{\partial x}\right)$$

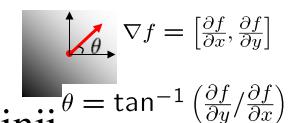
Extensia 1: folosește gradientul imaginii

- 1. inițializează H[d, θ]=0 (la fel)
- 2. pentru fiecare punct edgel din imagine I[x,y]

```
\theta = gradientul imaginii la (x,y)
d = x \cos Q + y \sin Q
H[d, \theta] += 1
```

- 3. găsește valorile (d^* , θ^*) pentru care H[d^* , θ^*] este maxim (la fel)
- 4. linia detectată în imagine este dată de: $d^* = x \cos \theta^* + y \sin \theta^*$

Extensii



Extensia 1: folosește gradientul imaginii

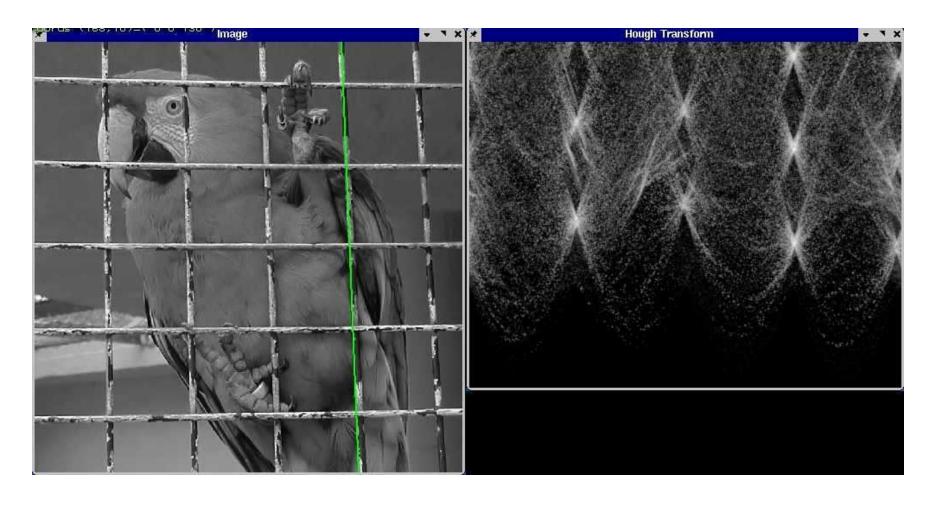
- 1. inițializează H[d, θ]=0 (la fel)
- 2. pentru fiecare punct edgel din imagine I[x,y]

```
\theta = \text{gradientul imaginii la } (x,y)
d = x \cos q + y \sin q
H[d, \theta] += 1
```

- 3. găsește valorile (d^* , θ^*) pentru care H[d^* , θ^*] este maxim (la fel)
- 4. linia detectată în imagine este dată de: $d^* = x \cos \theta^* + y \sin \theta^*$

Extensia 2: $H[d, \theta] += magnitudine gradient (x,y)$

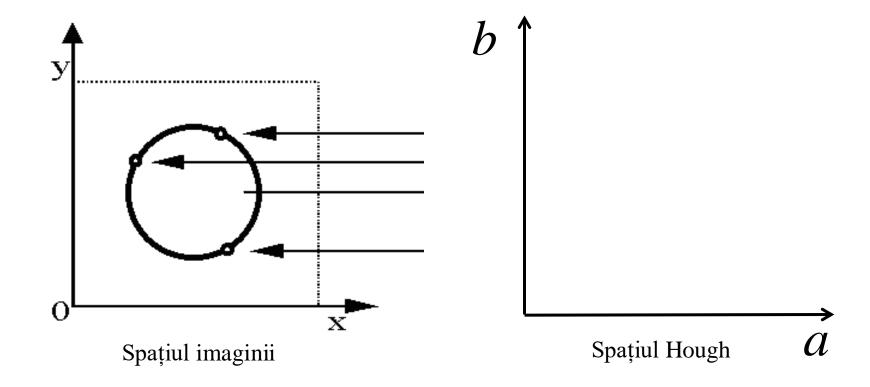
Transformata Hough - exemplu



• Cerc: centru (a,b) și raza r

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

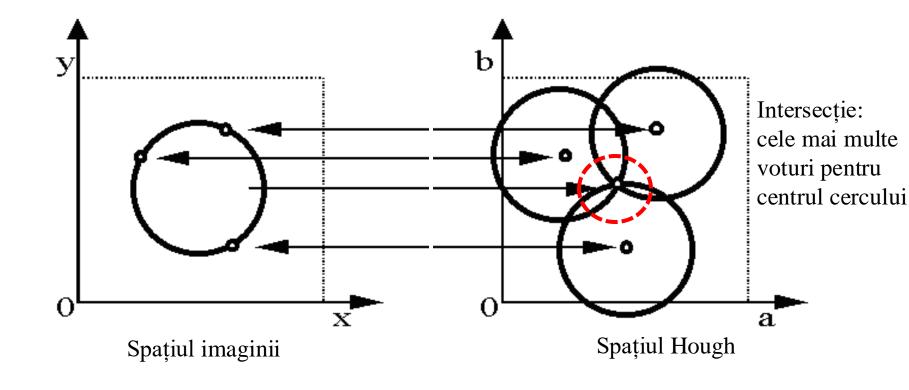
Pentru raza r fixată



• Cerc: centru (a,b) și raza r

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

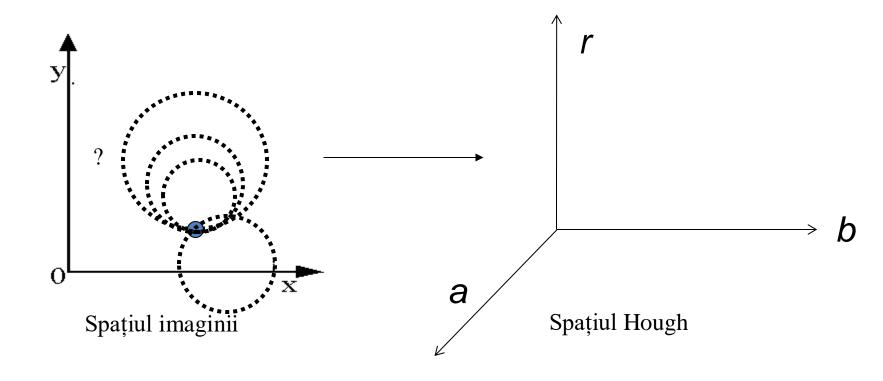
Pentru raza r fixată



• Cerc: centru (a,b) și raza r

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

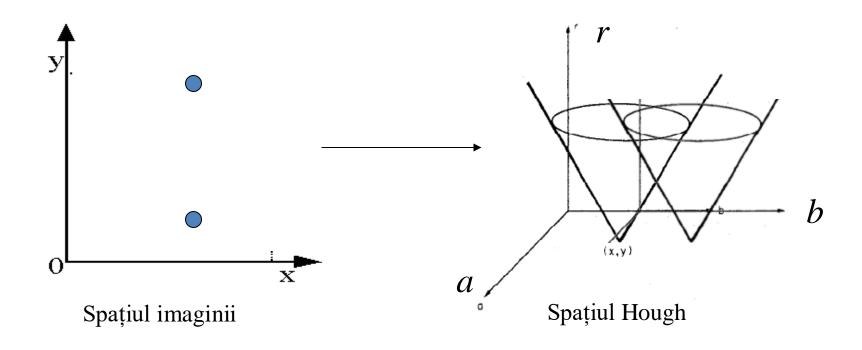
Pentru o rază necunoscută r



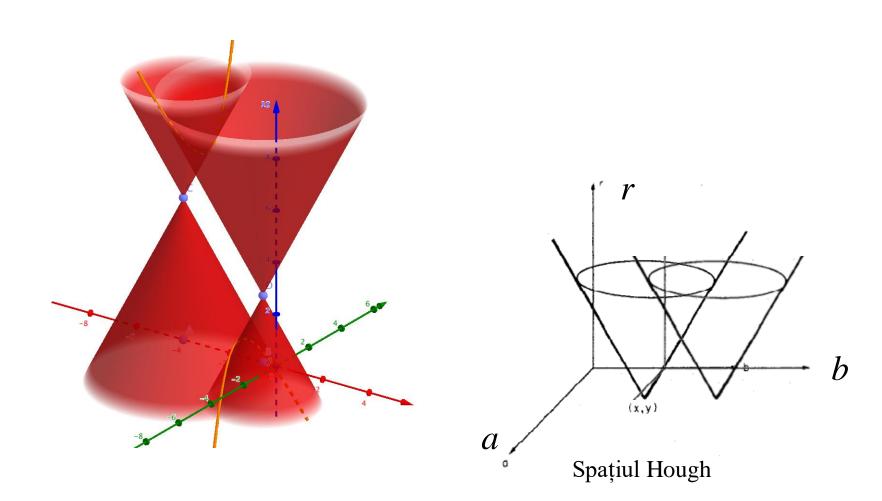
• Cerc: centru (a,b) și raza r

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

• Pentru o rază necunoscută r



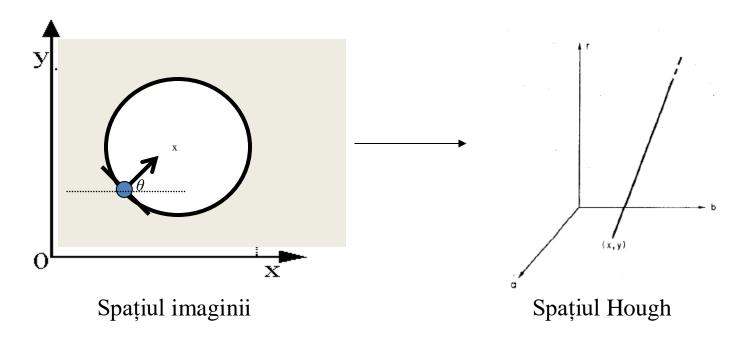
Intersecția a două conuri



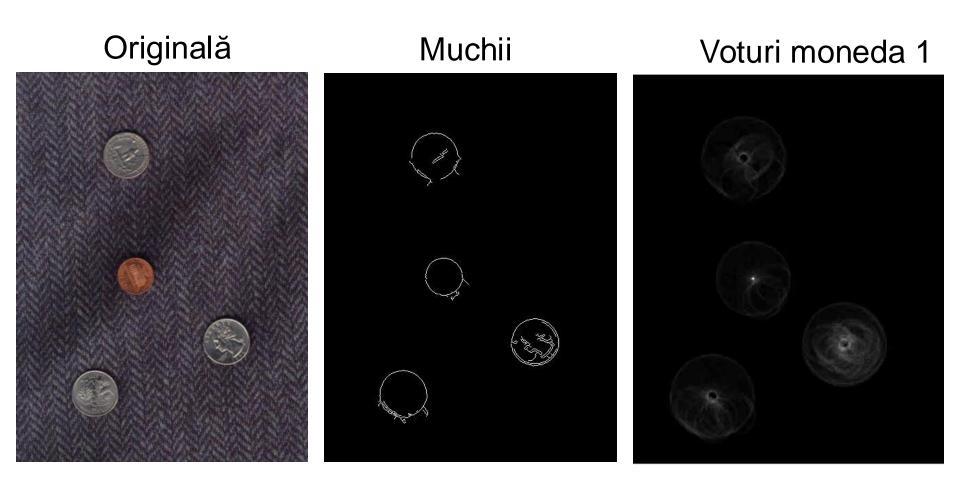
• Cerc: centru (a,b) și raza r

$$(x_i - a)^2 + (y_i - b)^2 = r^2$$

• Pentru o rază necunoscută r, cu direcția cunoscută a gradientului



Exemplu: detectarea cercurilor cu transformata Hough



Două transformate Hough folosite, una pentru fiecare rază a monedelor.

Exemplu: detectarea cercurilor cu transformata Hough

Detectirigimalanate Muchii Voturi moneda 2

Transformata Hough generalizată

Pattern Recognition Vol. 13, No. 2, pp. 111–122, 1981. Printed in Great Britain. 0031-3203/81/020111-12 \$02.00/0 Pergamon Press Ltd. © Pattern Recognition Society

GENERALIZING THE HOUGH TRANSFORM TO DETECT ARBITRARY SHAPES*

D. H. BALLARD

Computer Science Department, University of Rochester, Rochester, NY 14627, U.S.A.

(Received 10 October 1979; in revised form 9 September 1980; received for publication 23 September 1980)

Abstract—The Hough transform is a method for Artecting curves by exploiting the duality between points on a curve and parameters of that curve. The initial work showed how to detect both analytic curves^(1,2) and non-analytic curves,⁽³⁾ but these methods were restricted to binary edge images. This work was generalized to the detection of some analytic curves in grey level images, specifically lines,⁽⁴⁾ circles⁽⁵⁾ and parabolas.⁽⁶⁾ The line detection case is the best known of these and has been ingeniously exploited in several applications.^(7,8,9)

We show how the boundaries of an arbitrary non-analytic shape can be used to construct a mapping between image space and Hough transform space. Such a mapping can be exploited to detect instances of that particular shape in an image. Furthermore, variations in the shape such as rotations, scale changes or figure-ground reversals correspond to straightforward transformations of this mapping. However, the most remarkable property is that such mappings can be composed to build mappings for complex shapes from the mappings of simpler component shapes. This makes the generalized Hough transform a kind of universal transform which can be used to find arbitrarily complex shapes.

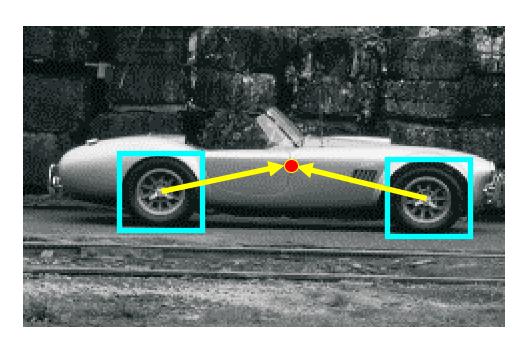
Image processing Parallel algorithms Hough transform

Shape recognition

Pattern recognition

Transformata Hough generalizată

folosește "cuvinte vizuale" care votează centrul obiectului





"cuvânt vizual" cu vectorul de deplasare

imagine de antrenare

B. Leibe, A. Leonardis, and B. Schiele, <u>Combined Object Categorization and Segmentation with an Implicit Shape Model</u>, ECCV Workshop on Statistical Learning in Computer Vision 2004

Transformata Hough generalizată

• folosește cuvinte vizuale care votează centrul obiectului

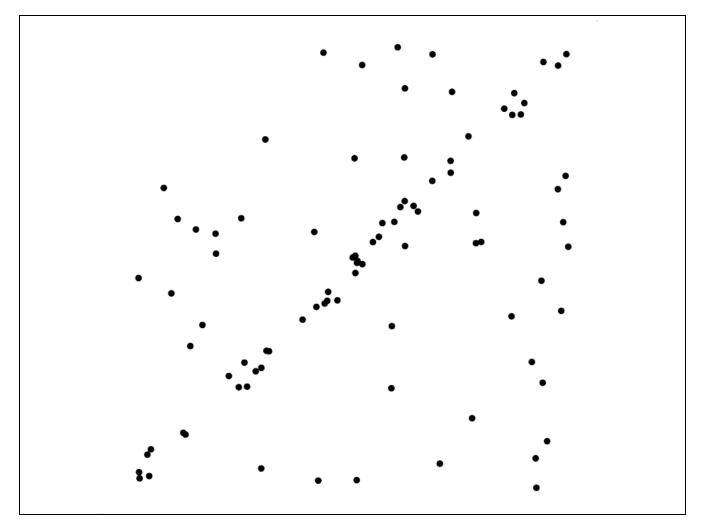


Imagine de testare

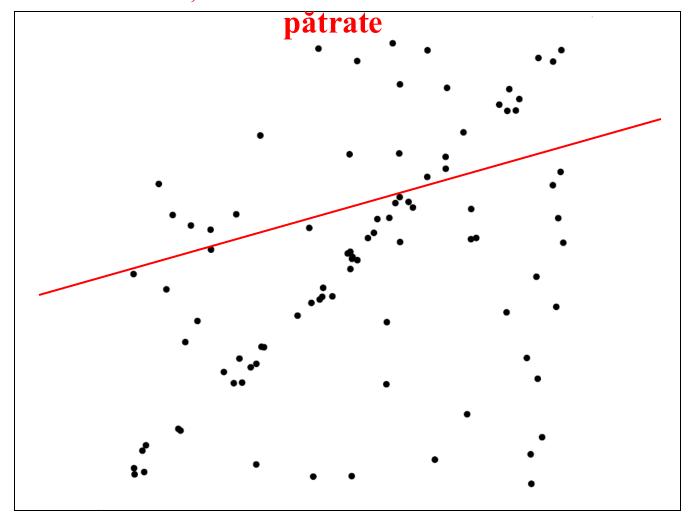
B. Leibe, A. Leonardis, and B. Schiele, <u>Combined Object Categorization and Segmentation with an Implicit Shape Model</u>, ECCV Workshop on Statistical Learning in Computer Vision 2004

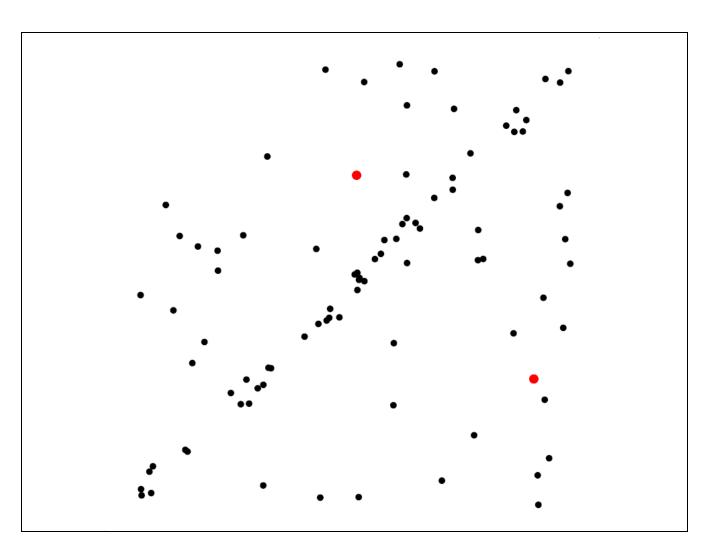
Aplicație: detectarea liniilor cu algoritmul RANSAC

Unde se află linia?

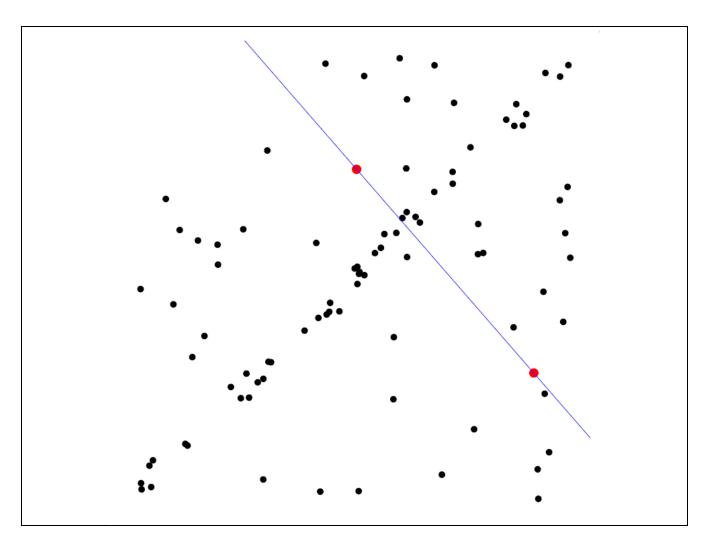


Soluția metodei celor mai mici

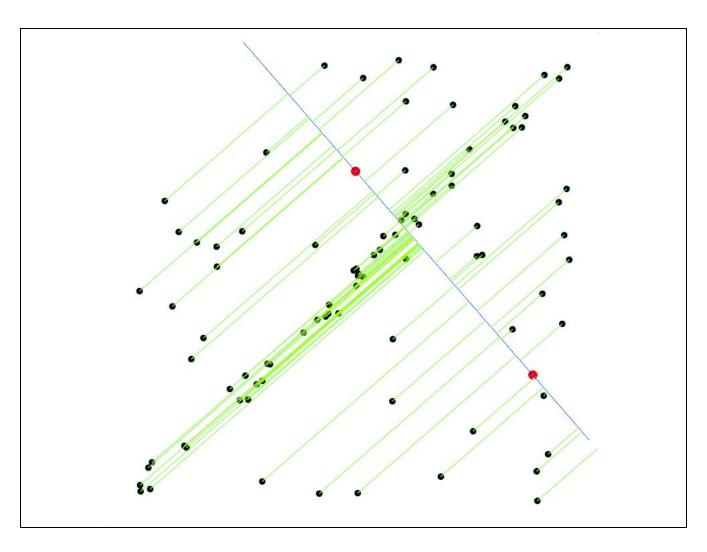




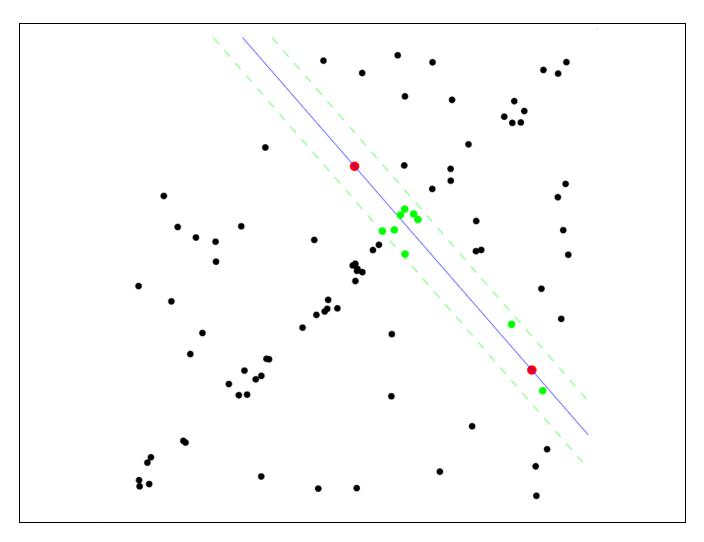
 Selectăm aleator 2 puncte dintre toate



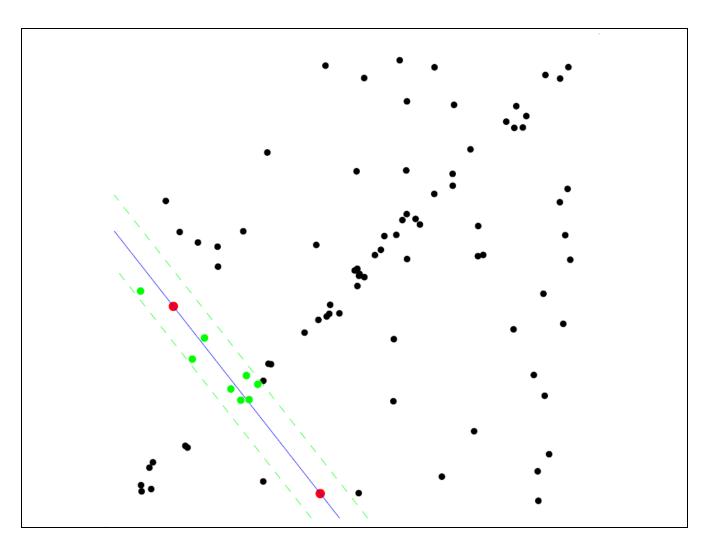
- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta



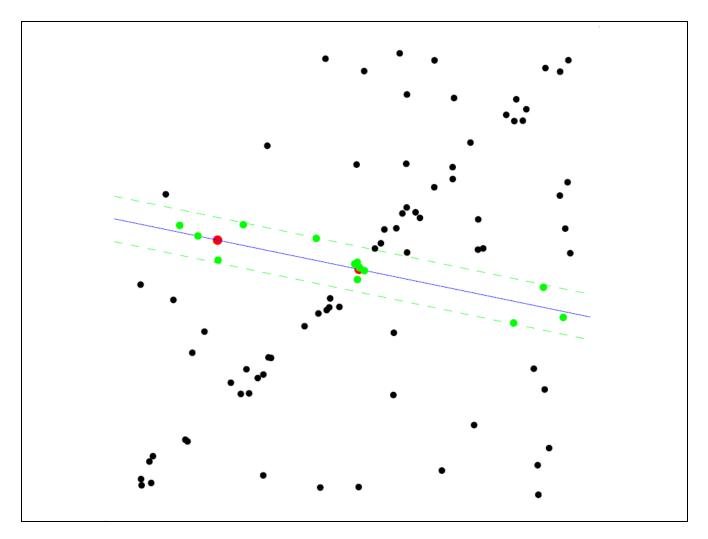
- 1. Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- 3. Calculăm funcția de eroare



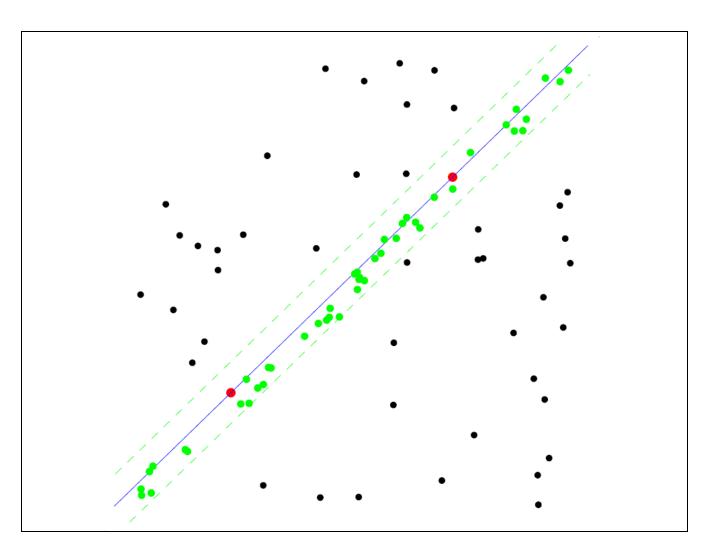
- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- 3. Calculăm funcția de eroare
- 4. Numărăm punctele inlier consistente



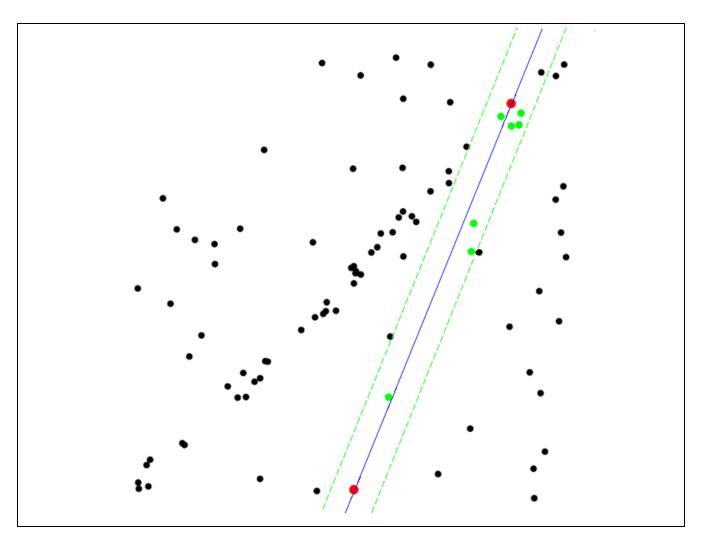
- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- 3. Calculăm funcția de eroare
- 4. Numărăm punctele inlier consistente
- 5. Repetă 1-4 pentru un număr de ori dat



- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- 3. Calculăm funcția de eroare
- 4. Numărăm punctele inlier consistente
- 5. Repetă 1-4 pentru un număr de ori dat



- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- Calculăm funcția de eroare
- 4. Numărăm punctele inlier consistente
- 5. Repetă 1-4 pentru un număr de ori dat



- Selectăm aleator 2 puncte dintre toate
- 2. Construim dreapta
- 3. Calculăm funcția de eroare
- 4. Numărăm punctele inlier consistente
- 5. Repetă 1-4 pentru un număr de ori dat

- RANdom SAmple Consensus
- idee principală: vrem să evităm impactul punctelor outlier, ne concentrăm să găsim punctele "inlier", și le folosim doar pe acestea la găsirea parametrilor modelului
- intuiție: dacă un punct outlier este inclus în dreaptă, numărul de puncte inlier va fi foarte mic (ipoteza nu este susținută de date)

Repetă de *N* ori:

- 1. Selectează 2 puncte la întâmplare
- 2. Găsește ecuației dreptei care trece prin aceste două puncte
- 3. Găsește punctele inlier pentru această ipoteză din cele rămase: punctele a căror distanță față de dreaptă este < *t* (threshold)
- 4. Dacă există mai mult de *d* puncte inlier, acceptă ipoteza. Rafinează ipoteza pe baza tuturor punctelor inlier.
- (Păstrează ipoteza cu cel mai mare număr de puncte inlier)

Algoritmul RANSAC: avantaje și dezavantaje

<u>Avantaje</u>

- simplu și general
- aplicabil în multe probleme (detectarea liniilor, construirea de panorame: găsirea de corespondențe – calculul homografiei - 8 parametri)
- funcționează destul de bine în practică

<u>Dezavantaje</u>

- numărul de parametri ai unui model poate fi foarte mare
- nu merge bine când numărul de puncte inlier este foarte mic (raportul inlier/outlier este mic)
- numărul minim de puncte ce definește un model nu furnizează întotdeaună ipoteze bune

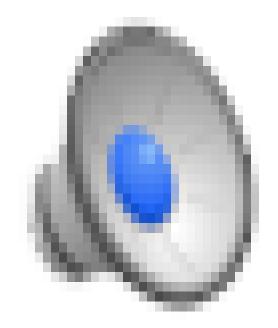
Algoritmul RANSAC: ce N alegem?

- de câte ori N trebuie să repetăm RANSAC pentru a fi siguri (cu o probabilitate mare) că am găsit cea mai bună ipoteză?
- presupunem că procentul de puncte provenite din dreaptă din numărul total de puncte este r (= #puncte inlier/nr puncte total)
- o ipoteză este definită de k puncte (k=2 pentru dreaptă)
- probabilitatea ca o selecție aleatoare de k puncte să fie corectă rk
- probabilitatea ca o selecție aleatoare de k puncte să fie greșită1 rk
- probabilitatea ca toate selecțiile să fie greșite: $(1 r^k)^N$
- probabilitatea ca cel puțin o selecție să fie corectă: $1 (1 r^k)^N$
- alege N astfel încât $p = 1 (1 r^k)^N$ este foarte mare (1-0.01=0.99)

RANSAC: Calculul lui N (p=0.99)

	Proporția de outlieri (1-r)							
k	5 %	10%	20%	25%	30%	40%	50%	
2	2	3	5	6	7	11	17	
3	3	4	7	9	11	19	35	
4	3	5	9	13	17	34	72	
5	4	6	12	17	26	57	146	
6	4	7	16	24	37	97	293	
7	4	8	20	33	54	163	588	
8	5	9	26	44	78	272	1177	

Aplicații – detectarea liniilor



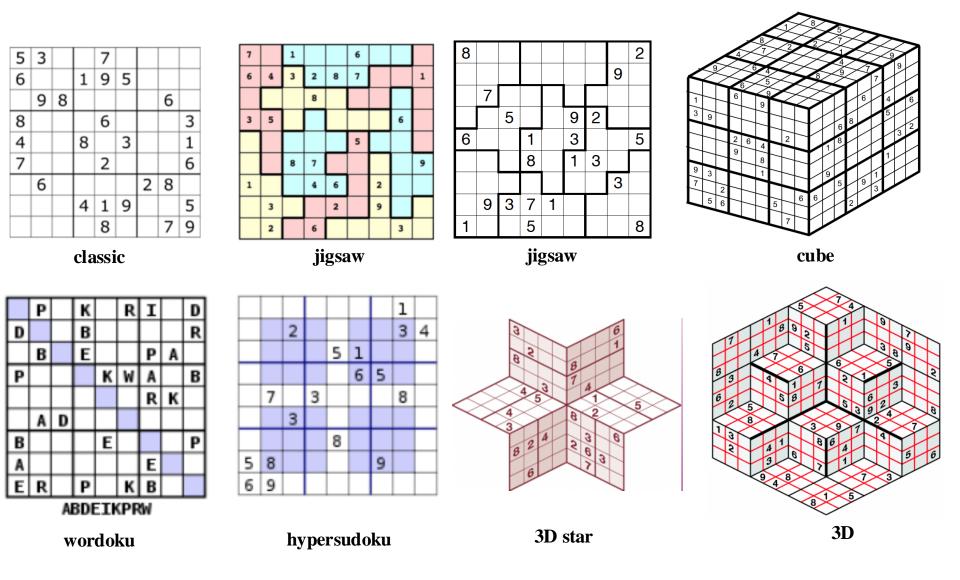
Aplicații - Extragerea informațiilor vizuale din careuri Sudoku

Sudoku is currently one of the most famous puzzles in the world. The most popular version consists on a 9×9 grid made up of 3×3 subgrids, but the general case, an $n^2 \times n^2$ grid with $n \times n$ subgrids is considered. Some cells contain numbers, which can be considered as input data. The goal is to fill in the empty cells, one number in each, so that each column, row, and subgrid contains the numbers 1 through 9 exactly once (numbers 1 to n^2 in the general case). If the input data are correct, the sudoku has one and only one solution.

5	3			7				
6			1	9	5			
	9	8					6	
8				6				3
8 4 7			8		3			1
7				2				6
	6					2	8	
			4	1	9			5
				8			7	9

5	3	4	6	7	8	9	1	2
6	7	2	1	9	5	3	4	8
1	9	8	ന	4	2	5	6	7
8	5	9	7	6	1	4	2	3
4	2	6	8	5	3	7	9	1
7	1	3	<mark>0</mark>	2	4	8	5	6
9	6	1	5	3	7	2	8	4
2	8	7	4	1	9	6	3	5
3	4	5	2	8	6	1	7	9

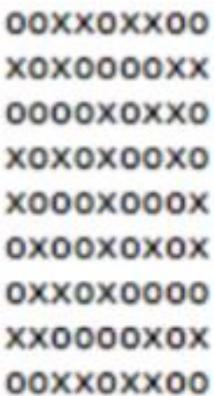
Multe variante de careuri Sudoku



- many more...

Classic Sudoku



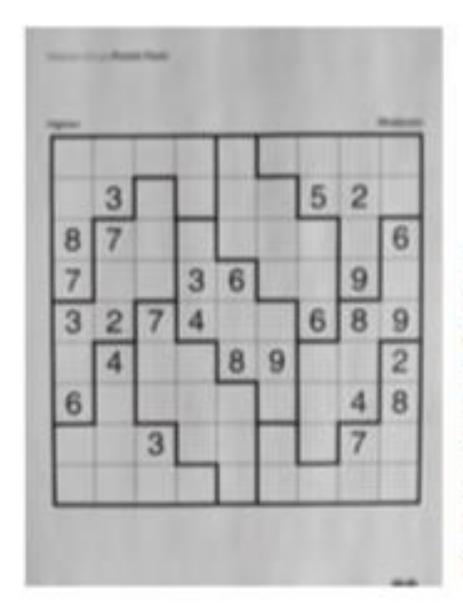


Jigsaw Sudoku



101x10101x10102020 3030104x4x104x4020 303x303x40404x2x2x 50503x303060404020 5x505x606x6x202x20 50506x60607070708080 9x506x709090708x8x 9x9090909080808080

Jigsaw Sudoku



```
10101010203030303030

101x40102020303x3x30

1x4x4050202020306x

1x40405x5x20203x60

4x4x7x5xm0502x6x6x

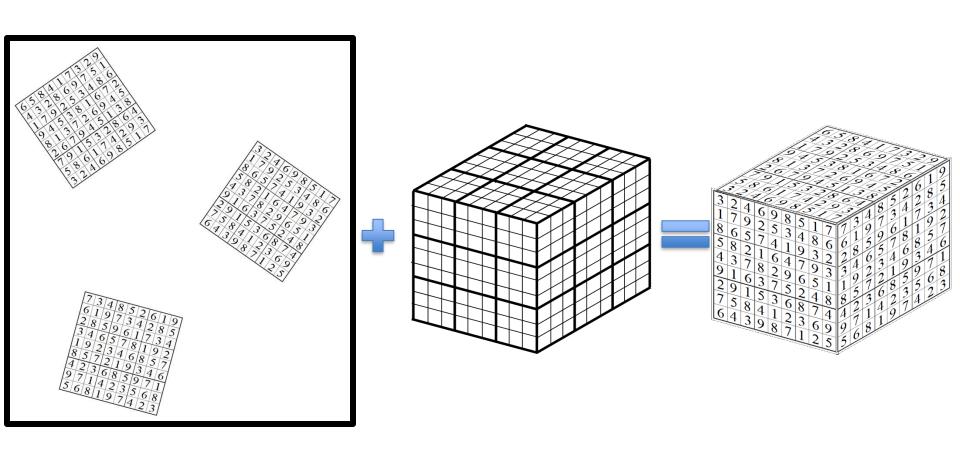
408x70705x5x60609x

4x8070707050606x9x

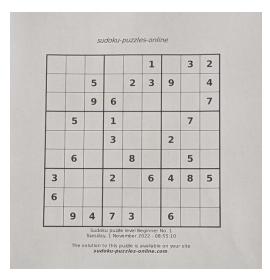
80808x707090609x90

808080807090909090
```

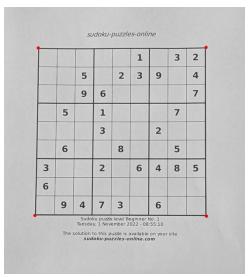
Sudoku Cube



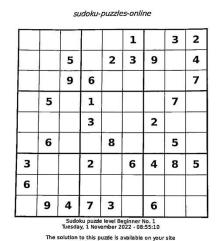
Aplicații: laborator săptămâna 6



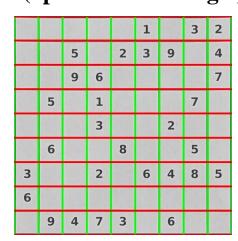
Imagine inițială



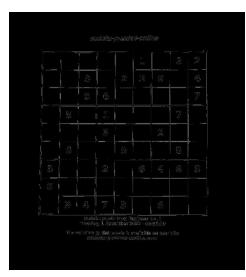
Cel mai mare contur închis



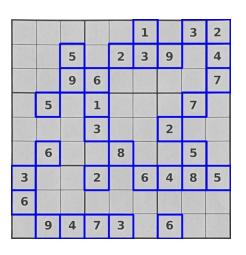
Gaussian blur + eroziune (operator morfologic)



Perspectivă + detectare de linii

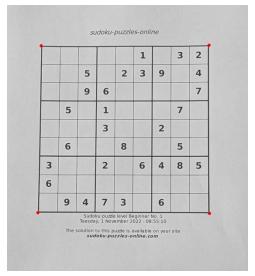


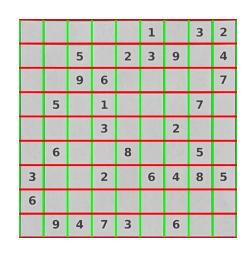
Canny edge detector

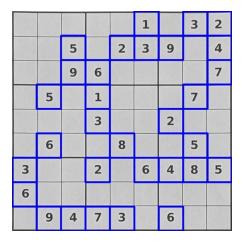


Clasificare celule

Aplicații: laborator săptămâna 6







Cel mai mare contur închis

Perspectivă + detectare de linii

Clasificare celule filled vs empty

```
[['o' 'o' 'o' 'o' 'o' '1' 'o' '3' '2']
['o' 'o' '5' 'o' '2' '3' '9' 'o' '4']
['o' 'o' '9' '6' 'o' 'o' 'o' 'o' '7']
['o' '5' 'o' '1' 'o' 'o' 'o' '7' 'o']
['o' 'o' 'o' '3' 'o' 'o' '2' 'o' 'o']
['o' '6' 'o' 'o' '8' 'o' 'o' '5' 'o']
['3' 'o' 'o' '2' 'o' '6' '4' '8' '5']
['6' 'o' 'o' 'o' 'o' 'o' 'o' 'o' 'o']
['o' '9' '4' '7' '3' 'o' '6' 'o' 'o']
```

Recunoaștere cifre în celule

Aplicații: lucrare de licență

Lucrare de licență

SOLUȚIE PENTRU SUDOKU 3D, BAZATĂ PE COMPUTER VISION

Absolvent Rusu Andrei-Cristian

Coordonator științific Conf. Dr. Alexe Bogdan

Cuprins

1	Introducere 5 1.1 Informații istorice 5 1.2 Sudoku 3D 6									
2	Baz	Baza de date și preprocesarea datelor 8								
3	Ter	minologie și convenții	11							
	3.1	Axele	11							
	3.2	Notația punctelor fețelor	11							
	3.3	Segmentele îngroșate	12							
4	Ext	ragerea informațiilor din imagine	13							
	4.1	Calcularea coordonatelor vârfurilor cubului	13							
	4.2	Identificarea segmentelor îngroșate	14							
	4.3	Extragerea vectorilor de deplasare a fețelor	15							
	4.4	Determinarea existenței unei fețe definite de patru puncte și extragerea								
		acesteia	15							
	4.5	Extragerea drumurilor folosind segmentele îngroșate	18							
		4.5.1 Extragerea punctelor de început ale fețelor	18							
		4.5.2 Algoritmul	21							
		4.5.3 Formulele pentru calculul punctelor fețelor din drumuri	21							
	4.6	Extragerea cifrelor din imagini cu fețe	27							
		4.6.1 Preprocesarea imaginii	27							
		4.6.2 Extragerea informației din celule	28							
		4.6.3 Clasificarea cifrelor din imagini	29							
5	Ger	nerarea soluției	31							
	5.1	Algoritmul	31							
	5.2	Verificarea validității unei configurații	33							
	5.3	Rezultate	34							
6	Cor	ncluzie	37							
Bi	Bibliografie 38									

Aplicații: lucrare de licență

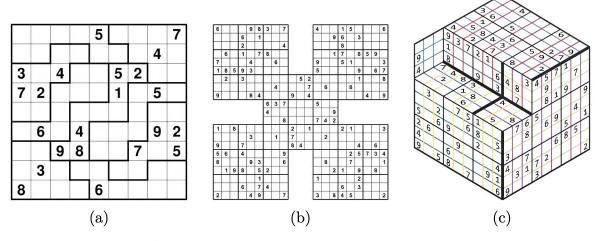


Figura 1.3: a) Sudoku Jigsaw; b) Sudoku Samurai; c) Sudoku 3D

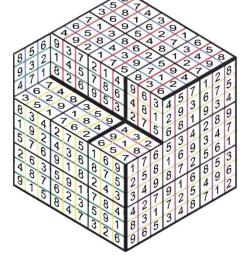
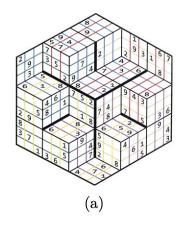
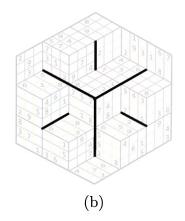
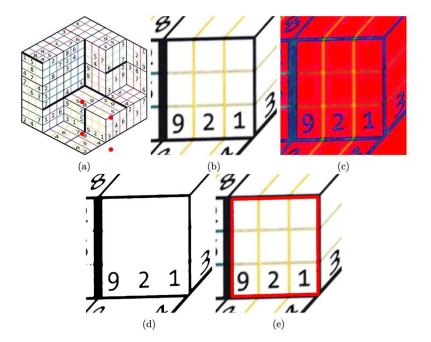


Figura 1.4: Soluția pentru configurația din **Figura** 1.3c







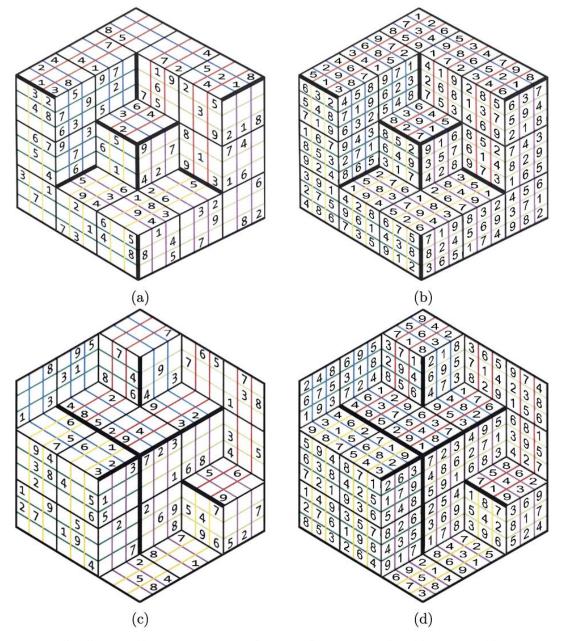


Figura 5.8: Configurațiile pentru care soluția a fost generată cel mai rapid, respectiv cel mai lent: a) imaginea 13; b) soluția, generată în 0.85s; c) imaginea 316; d) soluția, generată în 7.98s.

Compararea contururilor



Exemple de două imagini cu cifre scrise de mână. Comparând pixel cu pixel, cele două imagini sunt foarte diferite. Totuși, în termeni de formă, cele două imagini sunt similare.

Distanța Chamfer

• Distanța medie dintre punctele unui $template\ T$ și o mulțime de puncte (e.g. $puncte\ cu\ intensitate = 0$, puncte cu anumite caracteristici) dintr-o imagine I.

$$d_{chamfer}(T, I) = \frac{1}{|T|} \sum_{t \in T} d_I(t)$$

I= mulțime de puncte dintr-o imagine

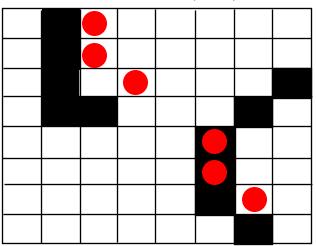
T= mulțime de puncte ale unui $\it template$

5 template

$$d_I(t) = ext{distanța minimă dintre } extit{punctul } t$$
 și un punct din I (Manhattan, Euclidiană)

Distanța Chamfer

Puncte din I (2D)



Distanța Manhattan:

$$\frac{1}{3}(1+1+2) = 1.33$$

$$\frac{1}{3}(0+0+1) = 0.33$$

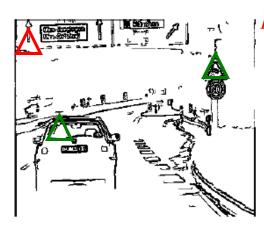


$$d_{chamfer}(T, I) = \frac{1}{|T|} \sum_{t \in T} d_I(t)$$

Distanța Chamfer

distanța medie până la cel mai apropiat punct din I

$$d_{chamfer}(T,I) = rac{1}{|T|} \sum_{oldsymbol{t} \in T} d_I(oldsymbol{t})$$
 Cum diferă distanța Chamfer de filtrarea cu o mască de forma lui T?



Imagine cu muchii

o mască de forma lui T?

Răspunsul variază mult mai puțin abrupt decât în cazul filtrării! (dacă mă mut la stânga/dreapta cu un pixel am valori apropiate)

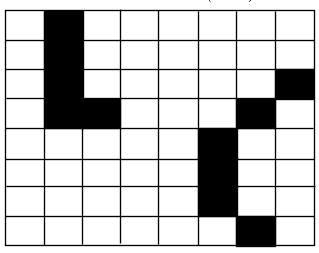
> Implementare naivă – complexitate?

 $|T| * |I|^2$ operații

Minimele locale ale funcției care calculează distanța Chamfer pentru fiecare fereastră

Transformata Distanță (distance transform)

Puncte din I (2D)



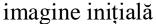
Transformata Distanță

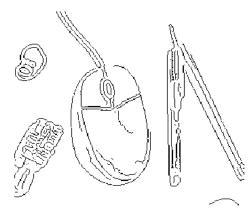
1	0	1	2	3	4	3	2
1	0	1	2	3	3	2	1
1	0	1	2	3	2	1	0
1	0	0	1	2	1	0	1
2	1	1	2	1	0	1	2
3	2	2	2	1	0	1	2
4	3	3	2	1	0	1	2
5	4	4	3	2	1	0	1

Transformata Distanță (TD) este o funcție care pentru fiecare pixel p asignează un număr pozitiv TD(p) corespunzând distanței de la p la cel mai apropiat punct din mulțimea I

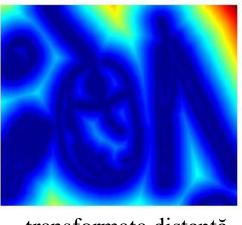
Transformata Distanță







muchii



transformata distanță

Calculăm o singură dată TD(), apoi citim din acest tabel distanța la cel mai apropiat punct de pe muchie.

OpenCV: cv.distanceTransform

Valoarea la (x,y) indică cât de departe (x,y) este de cel mai apropiat punct de pe muchie albastru – valori mici, roșu – valori mari